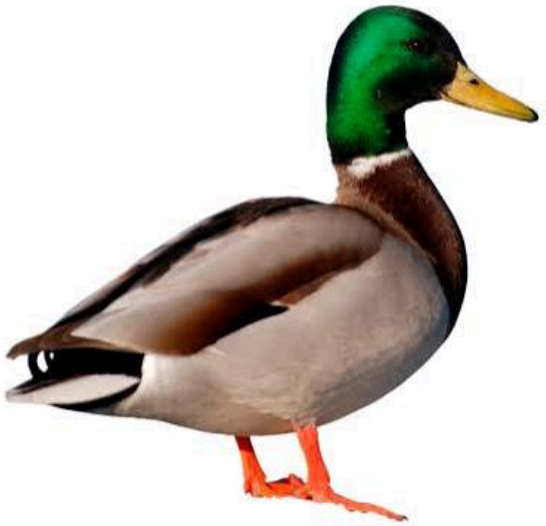
Ciência de Dados Aplicada ao Direito I

Aula 20

Uma análise do início ao fim



Prof. Bruno da Cunha de Oliveira - 2026/2

Gramática e vocabulário

Insper

Até aqui

Variáveis **Condicionais** **Listas** **Loops**

Dicionários **Funções** **Objetos**

Mas a gramática não é suficiente

Deblaterar

Deblaterar

falar com veemência contra alguém ou algo; bradar

Estugar

Estugar

apressar o passo; estimular, incitar

Bibliotecas aumentam o vocabulário

Vocês sabem a gramática do português, e mesmo assim não sabiam essas palavras. No Python é igual: a gramática vocês têm, e cada biblioteca traz palavras novas, prontas para importar e usar.

`jus.scraper`, `cjsg`, `raspe.camara` foram as primeiras. Quem sabe as palavras consegue dizer à IA, com precisão, o que quer.

Cada área tem o seu vocabulário

Área	Palavras que quem é de fora não usa
Direito	preclusão, litispendência, agravo interno
Medicina	anamnese, etiologia, prognóstico
Computação	compilador, cache, concorrência

Ninguém aprende todos. Cada um aprende o da área em que trabalha, e as bibliotecas também se dividem por área.

Os dois vocabulários do resto do curso

Bibliotecas	Para quê
para usar IA: LangChain	pedir a um modelo de linguagem, de dentro do programa, que leia, classifique e extraia
para bases de dados: pandas e as de gráfico	ler, filtrar, juntar e resumir tabelas, e desenhar o resultado

Em CDAD 2: conceitos de estatística e as bibliotecas de estatística.

Um cliente, três perguntas

Insper

Uma empresa quer entrar no Brasil

Uma empresa vende produtos médicos à base de canabidiol e quer começar a vender no Brasil. Ela sabe que boa parte do acesso a medicamentos aqui passa pela Justiça, e quer entender isso antes de decidir.

#	O que ela quer saber
1	As pessoas judicializam mais contra entes públicos ou contra privados?
2	Dentro de cada grupo, quem é mais acionado?
3	Quem ganha e quem perde?

Como vocês fariam?

Com o que vocês já sabem (o juscraper, objetos, listas, `for`), como tentariam responder às três perguntas?

Escrevam individualmente o seu palpite no formulário, com o máximo de detalhamento possível: de onde viriam os dados, o que faria com eles e quais dificuldades antecipam.

O caminho de hoje

RESPOSTA

Etapa	Hoje
coletar	sentenças do TJSP, já num CSV
abrir e olhar	pandas: uma tabela, colunas
extrair	o réu e o resultado, do texto
contar	público ou privado; quem ganha

Cada etapa ganha aulas próprias até o fim do curso. Hoje é a versão express.

A base de hoje

O que está no CSV do Blackboard

BUSCA

canabidiol

no banco de sentenças do TJSP, sem outro filtro

RESULTADOS

4.618

sentenças, em 462 páginas

NO CSV

300

30 páginas sorteadas, 10 por página

Coletada com o juscraper. Uma sentença por linha: classe, assunto, comarca, data e o texto inteiro.

O que o termo decide

A base veio da busca por "canabidiol". Se eu tivesse buscado "canabidiol OU CBD OU cannabis", ou filtrado só a classe "Mandado de Segurança", ou só 2025, ou o TJRJ, o que mudaria na resposta ao cliente?

O resultado vem do mundo ou da coleta?

RESPOSTA

O que aparece como "quem é mais acionado" pode ser um fato do mundo ou um efeito do que eu decidi coletar: o termo, a classe, o período, o tribunal e a instância.

Antes de responder ao cliente, cada uma dessas escolhas precisa estar escrita e justificada. Como escolher bem é a próxima aula. Hoje a base é esta.

Abrir a base

Abrir o CSV

Baixem `decisoes-canabidiol-tjsp.csv` do Blackboard para a pasta `cdad1` e, no caderno:

```
import pandas as pd

decisoes = pd.read_csv("decisoes-canabidiol-tjsp.csv")
print(len(decisoes))
print(decisoes.columns)
```

O que cada `print` mostra?

300 linhas, cinco colunas

RESPOSTA

```
300
Index(['classe', 'assunto', 'comarca', 'data', 'texto'],
dtype='str')
```

`read_csv` lê o arquivo e devolve um DataFrame: uma tabela, com linhas e colunas. `len` conta as linhas; `.columns` lista os nomes das colunas.

Onde está o que o cliente quer?

As colunas são `classe`, `assunto`, `comarca`, `data` e `texto`. Qual delas diz quem é o réu? E qual diz quem ganhou?

Nenhuma coluna pronta: está no texto

RESPOSTA

Nenhuma. O banco de sentenças do TJSP não entrega as partes nem o resultado como coluna. As duas informações estão dentro de `texto`, e o trabalho de hoje é tirá-las de lá e pô-las em colunas novas.

Uma coluna se acessa pelo nome entre colchetes: `decisoes["texto"]`.

Só o começo de cada texto

Cada sentença tem páginas. Para olhar várias de uma vez, basta o começo. Em Python, um pedaço de um texto se pega com colchetes e dois-pontos:

```
texto = "SENTENÇA\n\nProcesso Digital nº: 1500375-25.2024..."
print(texto[:8])
print(texto[:20])
```

O que cada `print` mostra?

Fatia: do começo até a posição que vocês pedem

RESPOSTA

```
SENTENÇA
SENTENÇA

Processo D
```

`[:8]` é a fatia do texto do começo até o caractere 8, sem ele; `[:20]`, até o 20. Vale para texto e para lista: `[:5]` numa coluna são as cinco primeiras linhas. A contagem começa no zero.

Criar uma coluna nova

```
import pandas as pd

decisoes = pd.read_csv("decisoes-canabidiol-tjsp.csv")
decisoes["inicio"] = decisoes["texto"].str[:200]
print(decisoes.columns)
print(decisoes["inicio"][7])
```

Seis colunas, e o começo da linha 7

```
Index(['classe', 'assunto', 'comarca', 'data', 'texto',
'inicio'], dtype='str')
SENTENÇA

Processo nº:  0004177-52.2023.8.26.0664
Classe - Assunto  Procedimento do Juizado Especial da Fazenda
Pública - Fornecimento de medicamentos
Requerente: Maria José Caetano
Requerido:  Fazenda P
```

O que a linha nova fez

Pedaço	O que é
`decisoes["inicio"] = ...`	coluna nova, criada ao receber um valor
`decisoes["texto"].str`	as operações de texto, aplicadas a cada linha da coluna
`[:200]`	a fatia: os 200 primeiros caracteres de cada texto
`decisoes["inicio"][7]`	a coluna, e dentro dela a linha 7 (a oitava: a contagem começa no zero)

Ler cinco decisões

Insper

Os cinco primeiros textos, o começo de cada um

```
import pandas as pd

decisoes = pd.read_csv("decisoes-canabidiol-tjsp.csv")
for texto in decisoes["texto"][:5]:
    print(texto[:200])
    print("----------")
```

`[:5]` pega as cinco primeiras linhas da coluna; `[:200]`, o começo de cada texto. Leiam o que sai.

A primeira

```
SENTENÇA
Processo Digital nº:  1500375-25.2024.8.26.0344
Classe - Assunto  Petição Cível - Petição intermediária
Requerente: Braz Bento dos Santos
Requerido:  Fazenda Pública do Estado de São Paulo e ou
```

A segunda, igual

```
SENTENÇA
Processo Digital nº:  1052225-21.2022.8.26.0224
Classe - Assunto  Procedimento Comum Cível - Tratamento
médico-hospitalar
Requerente: Enzo Henrique Rodrigues Chagas
Requerido:  UNIMED DE GUARUL
```

A terceira não começa assim

```
TERMO DE CONCLUSÃO
Eu,           JHENYFFER SANTINA MARIA REIS MORES, Estagiário
Nível Superior, matr. nº E50318838, em 26 de fevereiro de
2024, faço estes autos conclusos ao(à) MM. Juiz(a) de Direito
```

Nem a quarta

```
SENTENÇA

Processo nº:  1019802-69.2023.8.26.0451 - 2023/001900

Vistos.

Matheus Mondoni de Oliveira, ajuizou Ação Procedimento Comum
Cível contra Unimed de Piracicaba alegando, em síntese,ser ade
```

Que padrão vocês veem?

Nas duas que começam pelo cabeçalho, onde está o réu? E quem pede?

Se bastasse procurar esse padrão em cada texto, o que vocês coletariam de cada sentença?

Requerente e Requerido

RESPOSTA

O cabeçalho traz `Requerente:` e `Requerido:`, cada um seguido do nome, até o fim da linha. A intuição é boa: basta procurar esse padrão em cada texto e guardar o que vem depois.

A ideia inicial seria coletar os dois. Antes de fazer isso, uma pergunta.

O que identifica uma pessoa

Insper

Coletar os dois?

Vocês acabaram de ler o nome de quem pediu o canabidiol e, no corpo da sentença, a doença que ela tem.

Se o nosso CSV ganhar a coluna `requerente` e for parar no repositório do grupo, no GitHub, o que acontece? Vocês veem algum problema?

Dado pessoal, e de saúde

RESPOSTA

Lei Geral de Proteção de Dados. Art. 5º, I.

> I - dado pessoal: informação relacionada a pessoa natural identificada ou identificável;

A sentença é pública, e isso não torna o nome junto da doença um dado livre para qualquer uso. Para o cliente, quem pede não importa: importa contra quem se pede. Hoje coletamos só o `requerido`.

Basta procurar o padrão

Expressão regular: um padrão escrito em código

Expressão regular (regex) é uma linguagem pequena, dentro do Python, para descrever um padrão de texto: "a palavra Requerido, dois-pontos, e depois tudo até o fim da linha".

Ela tem uma gramática própria, cheia de símbolos. Não vamos aprendê-la hoje: vamos pedir ao assistente do VS Code, que a escreve bem, e conferir o resultado.

Peçam ao assistente

No caderno, peçam ao assistente do VS Code, em palavras:

> "Uma expressão regular que pegue, em cada texto da coluna `texto`, o que vem depois de `Requerido:` até o fim da linha, e guarde numa coluna nova `requerido`."

Rodem o que ele devolver e contem quantas linhas ganharam valor.

A que eu recebi, com acerto de 269 de 300

RESPOSTA

```
decisoes["requerido"] = decisoes["texto"].str.extract(
    r"Requerid[oa]s?:\s*([^\n]+)")
print(decisoes["requerido"].notna().sum())
print(decisoes["requerido"][:5])
```