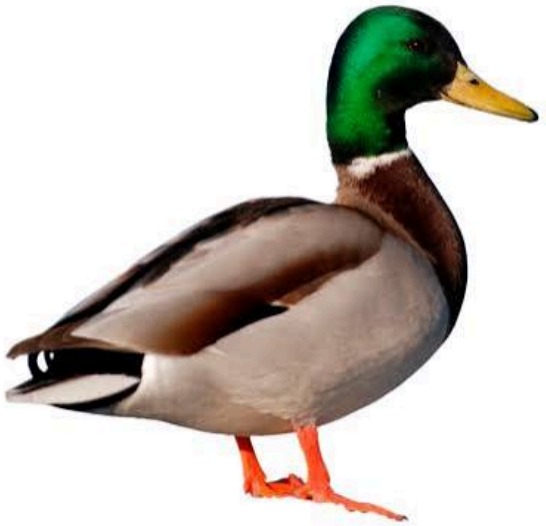
Ciência de Dados Aplicada ao Direito I

Aula 22

Do canabidiol ao Tema 1.417



Prof. Bruno da Cunha de Oliveira - 2026/2

Onde estamos

Insper

O que já respondemos à empresa de canabidiol?

A empresa fez três perguntas sobre as 300 sentenças do TJSP: contra quem se judicializa mais, quem é mais acionado em cada grupo, e quem ganha.

Para cada uma: como respondemos, e o que ficou faltando?

Três perguntas, três regras, três ressalvas

RESPOSTA

Pergunta	Como respondemos	O que faltou
Público ou privado?	regex do réu e regra por palavras: 196 de 300 contra o Estado	12 sem réu; "canabidiol" puxa o SUS
Quem é mais acionado?	contar o réu	a mesma Fazenda escrita de três jeitos
Quem ganha?	regex do dispositivo	40 de 300 sem classe

Outra maneira: utilizando Inteligência Artificial

Quem mais poderia preencher as três colunas?

Em vez de descrever o padrão do texto, dá para pedir a alguém que leia cada sentença e responda: quem é o réu, se é público ou privado, qual foi o resultado.

Ler 300 à mão leva um dia. Quem mais lê texto e responde em formato fixo?

Um modelo de linguagem

RESPOSTA

Um modelo de linguagem lê a sentença e preenche o formulário. Chamado de dentro do programa, ele faz isso para cada linha da tabela.

Para isso precisamos de três coisas: uma chave de acesso a um serviço que roda o modelo, um formulário com as perguntas, e a biblioteca que liga os dois à tabela.

Criar a conta e a chave na Groq

#	O que fazer
1	Abrir `console.groq.com` e entrar com a conta do Google, do GitHub ou um e-mail
2	No menu, **API Keys**, e depois **Create API Key**; dar um nome, como `cdad1`
3	Copiar a chave agora: ela começa com `gsk_`

A chave diz à Groq quem está pedindo: pedido, cota e cobrança caem na conta de quem a criou. Não mandem a ninguém, nem para mim.

Onde guardar a chave

O jeito mais rápido é colar a chave no próprio programa:

```
chave = "gsk_..."
```

O programa funciona. O que pode dar errado?

A chave escrita no código

Animação no navegador: `animacao-api-llm.html`, cenário `codigo`.

A chave vai junto com o arquivo

RESPOSTA

O arquivo vai para o repositório, e a chave vai junto: no repositório da fase 2, quem o abrir usa a conta de vocês. Apagar a linha e enviar de novo não resolve, porque a versão anterior continua no histórico.

Chave que vazou se apaga no painel da Groq, em **API Keys**, e se troca por outra.

A chave no arquivo .env

#	O que fazer, na pasta `cdad1`
1	No terminal do VS Code: `uv add python-dotenv`
2	Criar o arquivo `.env`, com uma linha só: `GROQ_API_KEY=` e a sua chave colada depois do =
3	Abrir o arquivo `.gitignore` e acrescentar uma linha com `.env`

O `.gitignore` lista o que o Git não registra: o `.env` fica no computador e nunca vai para o GitHub.

Conferir a chave

```python
import os
from dotenv import load_dotenv

load_dotenv()
chave = os.environ["GROQ_API_KEY"]
print(chave[:4])
```

No caderno da aula 22, passo 1. O que aparece? E se o `.env` não existisse?

os.environ lê o ambiente

RESPOSTA

```
gsk_
```

O `load_dotenv()` leva o que está no `.env` para o ambiente, e `os.environ` é um dicionário com ele. Sem o arquivo, a chave não existe:

```
KeyError: 'GROQ_API_KEY'
```

Só os quatro primeiros caracteres vão para a tela: a chave inteira nunca aparece num print.

O modelo preenche a tabela

Ler o README de uma biblioteca

A biblioteca é o dataframeit, no GitHub. O README de uma biblioteca costuma ter o que basta para a primeira chamada: como instalar, um exemplo mínimo e a lista de argumentos.

```
uv add "dataframeit[groq]"
```

Vamos ler juntos o exemplo do README e adaptá-lo às nossas três perguntas.

O formulário

```
from typing import Literal
from pydantic import BaseModel
class Formulario(BaseModel):
    requerido: str
    polo_passivo: Literal["público", "privado"]
    resultado: Literal["procedente",
                       "parcialmente procedente",
                       "improcedente",
                       "extinto sem julgamento do mérito"]
```

O que cada linha da classe diz

Um campo por linha: nome, dois-pontos e tipo. `Literal` fecha a lista de valores que o modelo pode devolver; `str` é texto livre. A classe herda de `BaseModel` o trabalho de conferir cada resposta.

Uma chamada para dez sentenças

```
from dataframeit import dataframeit
dez = decisoes.head(10)
tabela = dataframeit(dez, Formulario,
    "Leia a sentença e preencha os campos: {texto}",
    provider="groq", text_column="texto")
print(tabela[["requerido", "polo_passivo", "resultado"]])
```

`head(10)` separa as dez primeiras das 300, para a chamada ser curta. Uma linha de cada vez: o texto vai a um servidor da Groq, o modelo responde, a classe confere. A chave não aparece: o dataframeit a lê do ambiente.

Os argumentos do dataframeit

Argumento	O que é
`dez`	as dez primeiras sentenças, uma por linha
`Formulario`	o formulário, que confere cada resposta
o texto com `{texto}`	o pedido ao modelo; cada sentença entra no lugar de `{texto}`
`provider="groq"`	o serviço que roda o modelo; a chave vem de `GROQ_API_KEY`
`text_column="texto"`	a coluna em que está o texto

Rodem nas dez

No caderno, passos 2 a 4. Leva alguns segundos por sentença.

Deu certo quando `tabela` tem dez linhas e três colunas novas, cada uma com um valor que a classe aceitou.

Dez linhas vazias

```
ERRO DE AUTENTICAÇÃO - Chave de API inválida
...
  requerido polo_passivo resultado
0      None          None      None
1      None          None      None
2      None          None      None
```

O programa não para: cada linha que falha volta vazia, e o aviso fica acima da tabela. Quando é a chave, conferir o `.env` (o nome é `GROQ_API_KEY`, sem espaço em volta do =) e o passo 1.

Os dois caminhos lado a lado

Insper

Guardar antes de comparar: `to_csv`

```
dez = decisoes.head(10)
dez["requerido_regex"] = dez["texto"].str.extract(
    r"Requerid[oa]s?:\s*([^\n]+)")
dez.to_csv("dez-decisoes-regex.csv", index=False)
```

`to_csv` grava a tabela num arquivo; `index=False` deixa de fora a numeração das linhas. O caderno gravou `tabela`, a do modelo, do mesmo jeito. Com os dois arquivos salvos, a comparação não depende de rodar tudo de novo.

As mesmas dez, regex contra modelo

```
import pandas as pd

regex = pd.read_csv("dez-decisoes-regex.csv")
modelo = pd.read_csv("dez-decisoes-modelo.csv")

regex["requerido_modelo"] = modelo["requerido"]
print(regex[["requerido_regex", "requerido_modelo"]])
```

`read_csv` relê os dois arquivos. Onde as duas colunas diferem, quem acertou?

Quando usar cada um?

Nas dez sentenças, comparem os resultados e discutam em dupla:

#	Pergunta
1	Em que tarefa a regex basta, e por quê?
2	Em que tarefa o modelo é melhor, e o que ele custa?
3	Como vocês saberiam quantas respostas do modelo estão certas?

Regra para o que tem forma, modelo para o que tem sentido

RESPOSTA

	Expressão regular	Modelo de linguagem
acerta	em texto de forma fixa	em texto variado
custa	testar a regra	uma chamada por linha
erra	em silêncio	com confiança
se confere	lendo o vazio	lendo uma amostra

Um cliente novo

Desta vez, a base não vem pronta

	Canabidiol	O cliente novo
a base	300 sentenças, prontas no CSV	coletamos nós
a busca	"canabidiol", escolhida antes	termos, tribunal e período: escolha nossa
a análise	três perguntas do cliente	as perguntas também são nossas

Vamos fazer algo parecido, do começo: o que perguntar, o que buscar e como analisar depois.

Uma grande companhia aérea

O escritório quer conquistar uma grande companhia aérea como cliente. A diretoria jurídica dela mandou uma mensagem curta:

Descobri que tem esse recurso no STF. Me conta como isso vai me afetar.

O recurso é o ARE 1.560.244, que o STF julga como Tema 1.417.

Tema 1.417, em resumo

O quê	Resumo
a pergunta	para atraso, cancelamento ou alteração de voo por caso fortuito ou força maior, vale o Código Brasileiro de Aeronáutica ou o Código de Defesa do Consumidor?
a base	art. 178 da Constituição, que manda a lei ordenar o transporte aéreo
o relator	Min. Dias Toffoli; repercussão geral reconhecida em agosto de 2025
o mérito	sem julgamento e sem data de pauta

A suspensão nacional

Quando	O que o relator decidiu
26/11/2025	suspendeu, no país inteiro, os processos sobre a questão do tema, até o julgamento
10/03/2026	esclareceu o alcance: ficam parados os casos de meteorologia, infraestrutura do aeroporto, ordem de autoridade e pandemia (art. 256, § 3º, do CBA); falha da própria companhia, como manutenção ou overbooking, segue tramitando

Para a companhia, a mesma ação pode estar parada ou andando, conforme o motivo do atraso.

Sentenças com "atraso de voo" no TJSP

No ano anterior à suspensão (27/11/2024 a 26/11/2025), a busca de sentenças do TJSP pela expressão "atraso de voo" devolve 15.975.

E nos onze meses seguintes (27/11/2025 a 02/11/2026)?

De 15.975 para 1.495

RESPOSTA

Busca no TJSP, 1º grau	Antes	Depois
"atraso de voo"	15.975	1.495
"cancelamento do voo"	18.087	1.510
"Tema 1417" ou "1.560.244"	1	1.153

Contagem do juscraper em 02/11/2026. A queda não diz sozinha quantas ações a suspensão parou: o termo de busca, o período e o que conta como sentença mudam o número.

O que vale a pena perguntar

Insper

Três perguntas para a companhia

Vocês estão no escritório que quer conquistar a companhia. Escrevam três perguntas que vocês responderiam com dados para ela, e mandem pelo Blackboard.

Para cada pergunta: que dado vocês coletariam para respondê-la?

Qual de cada par vocês levariam à companhia, e por quê?

#	A	B
1	Coletar todas as ações contra a companhia e ver o que aparece	Quantas ações dela estão paradas pela suspensão?
2	Que palavras mais aparecem nas sentenças?	Em quantas o juiz culpa uma falha da própria companhia?
3	Cruzar os dados da ANAC com todas as sentenças	Quanto ela deixa de pagar se o STF escolher o CBA?

Pergunta de pesquisa e mineração de dados

RESPOSTA

	Mineração (A)	Pesquisa (B)
começa por	os dados que houver	a decisão do cliente
o que coletar	tudo	o que a pergunta pede
a resposta	um padrão, talvez inútil	um número conferível

As perguntas de vocês

Vamos ler as respostas do Blackboard e classificar juntos: pergunta de pesquisa ou mineração?

Quando for mineração, o que falta para virar pergunta: o recorte, o número que se quer, ou a decisão que ele muda?

O caminho até a resposta

Etapa	No caso da companhia
definir a amostra	que termo, tribunal e período
o que coletar	que dado de passageiro fica de fora
coletar	raspar e guardar, com a ficha da coleta
extrair e conferir	o motivo do atraso, e quantas o modelo acerta
limpar e juntar	um nome por companhia; sentença com o processo
analisar	responder à companhia nos dois desfechos do STF

As perguntas que vamos responder

Das perguntas de pesquisa que sobraram, quais o escritório leva à companhia?

Escolhemos juntos as que vamos responder até o fim do curso.

Na próxima aula

Como saber quantas ações o Tema 1.417 alcança sem ler todas: o que uma amostra diz sobre o todo, e o que uma consulta mal feita esconde.