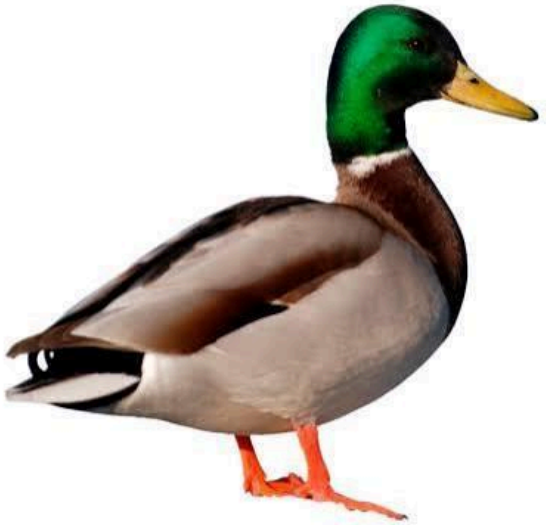
Ciência de Dados Aplicada ao Direito I

Aula 24

Viés de seleção e coleta



Prof. Bruno da Cunha de Oliveira - 2026/2

Os pareceres

Insper

Remédios contra planos no TJSP: contratar?

Na consulta	O que está escrito
O escritório	defende operadoras de planos e quer prever como o TJSP decide pedidos de medicamentos, inclusive nas liminares
A busca	"remédio", 1º grau do TJSP: 126.130; só 2025: 10.749
O título	Quando o TJSP joga dinheiro no lixo

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

Não contratar: pedir outra proposta

RESPOSTA

Na proposta	O problema
o termo "remédio"	entram o Estado e o "remédio processual"; sai o "medicamento"
só 2025 e só o 1º grau	conclui sobre "o TJSP" com um ano e sem as câmaras
o título já conclui	os casos são escolhidos para provar a tese
só sentenças	ficam fora as liminares, onde o custo aparece

Erro grosseiro no TCU: contratar?

Na consulta	O que está escrito
O escritório	defende gestores públicos, que só levam multa ou inabilitação com dolo ou erro grosseiro
A pergunta	como o TCU define "erro grosseiro" ao aplicar o art. 28 da LINDB
A busca	"LINDB" e "art. 28", acórdãos do Plenário, desde 26/04/2018: 729
O registro	uso do art. 28, enunciados, teses gerais, contradições

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

Contratar com mudanças

RESPOSTA

Na proposta	O problema
só o Plenário	as Câmaras também julgam gestores: o Plenário não é o TCU
busca por "art. 28"	sai quem diz "erro grosseiro" sem citar o artigo
729 decisões	quantas são do escopo? Ler uma amostra antes do preço
critérios abertos	não anotam a definição nem a punição

Despejo por falta de pagamento no TJSP: contratar?

Na consulta	O que está escrito
O escritório	atende uma administradora que precifica garantia de aluguel: tempo até a desocupação e quantas liminares saem
A busca	"despejo", acórdãos do TJSP, sem período: 213.580; analisa os 600 primeiros
O título	como decide o Tribunal
O registro	provimento, argumentos e tempo entre sentença e acórdão

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

Não contratar: pedir outra proposta

RESPOSTA

Na proposta	O problema
só acórdãos	só o despejo que teve recurso; o típico acaba no 1º grau, e o tempo sai maior
os 600 primeiros	a ordem é do buscador: não é amostra
o acórdão	não traz a desocupação nem a liminar, que estão no andamento do 1º grau
"despejo", sem data	pega o comercial, outros motivos e a pandemia

O STF no caso Master: contratar?

Na consulta	O que está escrito
O escritório	defende um investigado: como o STF se posiciona no caso?
O título	A perseguição ao STF no caso Master
A pergunta	como a mídia tem deturpado a imagem do STF com o caso Master
O material	a Pet 15556 e os correlatos que vierem; Folha, Estadão e O Globo; peças da PGR e decisões
Os autos	4 mil arquivos abertos em setembro; o resto segue em sigilo

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

Não contratar

RESPOSTA

Na proposta	O problema
pergunta e título	partem da conclusão, que nem é a do escritório
peças e decisões	4 mil arquivos abertos, sem critério do que ler; as diligências em curso seguem fechadas
três jornais	não são "a mídia"
um caso em curso	descreve o caso até uma data, não como o STF se posiciona

Nem todo defeito é viés de seleção

Defeito	O que fazer	Consultas
viés de seleção	mudar a forma de escolher, ou limitar a conclusão ao recorte	1, 2, 3, 4
tese a provar	pergunta descritiva, antes dos dados	1, 4
material que não responde	buscar o material que tem a resposta	1, 3, 4
casos demais	ler uma amostra sorteada	1, 2, 3

E se um modelo ler as 10.749?

Nas últimas aulas, um modelo de linguagem leu sentenças por nós. Com ele, a consulta 1 deixa de ter casos demais.

O que o modelo resolve na consulta 1, e o que continua igual?

O volume se resolve, a seleção não

RESPOSTA

O modelo resolve	Continua igual
ler todas as 10.749	as 10.749 vieram do termo "remédio", de 2025 e do 1º grau
extrair os campos de cada uma	a tese no título, que escolheu os casos

E o que o modelo extrai ainda se confere numa amostra lida por nós.

De volta à companhia

Insper

Contar as ações paradas

A companhia quer saber quantas ações dela estão paradas pela suspensão do Tema 1.417.

Um colega propõe: baixar as sentenças do TJSP com "atraso de voo" e contar.

> O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

A busca em sentenças não alcança quem parou antes dela

RESPOSTA

Na proposta do colega	O que acontece
Dentro	os processos que já chegaram à sentença
Fora	os que a suspensão parou antes dela, que são os que a companhia quer contar
A diferença	quem ficou fora é justamente quem a pergunta procura

Para contá-los, partir dos processos distribuídos e ainda sem sentença.

A nossa proposta à companhia aérea

O Tema 1.417, como o caso Master, ainda corre no STF.

Que pergunta a nossa proposta à companhia pode responder com dados, e qual ela não pode?

O que os dados respondem

RESPOSTA

Os dados	A pergunta
Não respondem	o que o STF vai decidir
Respondem	o que os processos já decididos dizem do risco da companhia, e quantos estão parados, por qual motivo de atraso

As perguntas de vocês

As perguntas que vamos responder

Pergunta	O que quer saber
A. Quanto o passageiro ganha	a taxa de vitória, no geral e por recorte: período, atraso ou cancelamento, valor
B. Com qual fundamento	que argumento e que lei decidem: CDC, CBA, excludentes
C. Quanto a suspensão alcança	quantas ações o Tema 1.417 parou
D. O que muda o resultado	como a taxa varia com cada característica

A pergunta D, com cuidado

"Quais variáveis **afetam** o resultado?" pergunta por causa.

O que uma base de sentenças mostra é **como a taxa varia** junto com cada característica: em cancelamento, ganha-se mais do que em atraso?

Importante

Descrever que duas coisas andam juntas é o que esta disciplina faz. Dizer que uma causa a outra fica para a CDAD-2.

Primeiro: que dado?

Para responder cada uma das quatro, que dado precisamos ter em mãos?

Dado é fato sobre o mundo, obtido por observação.

O dado de cada pergunta

RESPOSTA

	Dado
A	resultado, data, atraso ou cancelamento, valor da causa
B	lei aplicada, excludente alegada, se foi aceita
C	processos parados e o motivo do atraso
D	tudo o que está acima, junto

Depois: onde está esse dado?

Onde encontramos cada um desses dados?

A fonte de cada dado

RESPOSTA

Dado	Fonte
resultado, fundamento, excludente	texto da sentença
data, vara, companhia	dados da busca de sentenças
valor da causa	consulta do processo, e não a sentença
processos parados	processos distribuídos e ainda sem sentença

Olhar uma parte para entender o todo

Na fonte, queremos tudo?

Só a busca por "atraso de voo" nas sentenças do TJSP de 1º grau devolve 15.975 decisões, num ano.

Ler, baixar e conferir tudo isso custa caro. E, para as perguntas A e B, não é preciso.

Amostra: uma parte, escolhida para falar do todo

1. o exame de sangue tira um tubo, e não o sangue todo
2. a pesquisa eleitoral ouve uns 2 mil eleitores, e não 150 milhões
3. a cozinheira prova uma colher, desde que tenha mexido a panela

A colher só diz algo da panela se a panela foi mexida: é o sorteio que garante isso.

A amostra quase não cresce com o todo

Decisões na lista	Amostra, erro de 5 pontos	Amostra, erro de 2 pontos
1.000	278	706
15.975	375	2.087
100.000	383	2.345
1.000.000	384	2.395

Para estimar uma taxa, como a de vitória, com 95% de confiança e amostra sorteada.

Quanto custa ler: gente

10 min por sentença, hora a R$ 800	Tudo	Erro de 2 pontos	Erro de 5 pontos
sentenças	15.975	2.087	375
horas	2.663	348	63
custo	R$ 2,1 milhões	R$ 278 mil	R$ 50 mil

Nenhum cliente paga R$ 2 milhões para saber uma taxa que 375 decisões estimam com 5 pontos de erro.

Quanto custa ler: modelo de linguagem

GPT-5.6 Luna, 5.000 tokens de entrada e 500 de saída	Tudo	Erro de 2 pontos	Erro de 5 pontos
sentenças	15.975	2.087	375
tokens	88 milhões	11 milhões	2 milhões
custo	US$ 128	US$ 17	US$ 3

Ler tudo com o modelo custa menos que uma hora de advogado. O que custa é conferir: o que ele extrai se confere numa amostra lida por gente.

Antes de sortear, três decisões

1. **de onde** sortear: a lista que conseguimos montar, e quanto ela cobre do todo
2. **como** sortear: tirar da lista inteira, e não pegar as primeiras
3. **quantas** ler: o tamanho que a pergunta e o tempo permitem

De onde sortear: a lista

Universo, cadastro e amostra

Conjunto	No nosso caso
Universo	todas as ações de passageiros contra companhias aéreas por atraso ou cancelamento
Cadastro amostral	a lista que conseguimos montar: o que o buscador do TJSP devolve
Amostra	as decisões que sorteamos dessa lista e lemos

A amostra sai do cadastro, e não do universo (Lohr, cap. 1).

O cadastro não é o universo

O universo quase nunca está ao nosso alcance. O que alcançamos é uma lista, e ela tem buracos:

1. processos em segredo de justiça não aparecem na busca
2. processos sem sentença não estão numa busca de sentenças
3. a sentença que não usa as palavras buscadas fica de fora

O buscador do TJSP deve cobrir boa parte dos casos. A pergunta é sempre: o que ficou fora é diferente do que ficou dentro?

Outro cadastro: o DataJud

	Busca de sentenças do TJSP	DataJud (CNJ)
O que lista	sentenças publicadas	processos, com classe, assunto e movimentos
Sem sentença	não alcança	alcança, inclusive os suspensos
Como buscar	palavra, assunto, classe	assunto e classe, sem palavra-chave
Período	o do buscador	a partir de 2020
Texto	traz a sentença	não traz: só metadados

Qual cadastro? Depende da pergunta

Pergunta	Cadastro
A. Quanto o passageiro ganha	sentenças do TJSP: o resultado está no texto
B. Com qual fundamento	sentenças do TJSP: o fundamento está no texto
C. Quanto a suspensão alcança	DataJud: lista os processos parados, que não têm sentença

Os dois se juntam pelo número do processo: o DataJud dá a lista, e o raspador do TJSP busca o andamento e as decisões de cada processo sorteado.

O preço de partir do DataJud

1. sem palavra-chave, o assunto traz também o que não é atraso nem cancelamento de voo
2. quanto do assunto é de fato relevante? Só lendo uma amostra para estimar
3. antes de 2020 não há dados
4. cada processo sorteado pede uma consulta a mais no TJSP

Mais caro de montar, mas é o único dos dois que enxerga quem parou antes da sentença.

Que busca vocês fariam?

Em grupo: montem a busca no TJSP que gera a lista das ações de atraso e cancelamento de voo.

1. qual cadastro: busca de sentenças do TJSP ou DataJud
2. 1º grau, 2º grau, ou os dois
3. termo livre (quais palavras, com ou sem aspas), assunto ou classe
4. que período
5. o que a busca de vocês deixa de fora

Sentenças com "atraso de voo" no TJSP

No ano anterior à suspensão (27/11/2024 a 26/11/2025), a busca de sentenças do TJSP pela expressão "atraso de voo" devolve 15.975.

E nos onze meses seguintes (27/11/2025 a 02/11/2026)?

De 15.975 para 1.495

RESPOSTA

Busca no TJSP, 1º grau	Antes	Depois
"atraso de voo"	15.975	1.495
"cancelamento do voo"	18.087	1.510
"Tema 1417" ou "1.560.244"	1	1.153

Contagem do juscraper em 02/11/2026. A queda não diz sozinha quantas ações a suspensão parou: o termo de busca, o período e o que conta como sentença mudam o número.

Cada escolha muda a lista

RESPOSTA

Escolha	Na coleta-piloto
"atraso de voo", com aspas	15.975
sem aspas	34.503: as palavras se ligam com E
com acento ("vôo")	12.898
assunto 4829	21.867
o que o termo pega	das 20 primeiras, 5 fora do ramo aéreo

A ficha da coleta

Antes de baixar qualquer coisa, anotar:

1. tribunal e grau (TJSP de 1º ou de 2º grau, STJ, STF)
2. termos exatos, com aspas e variações, ou assunto e classe
3. período, e por que ele
4. o que conta como decisão (sentença, acórdão, liminar)
5. data e hora da busca, e quantas decisões ela devolveu

Quem repetir a busca tem que chegar ao mesmo cadastro.

Como sortear

Como na consulta 3: as primeiras não são amostra

Na consulta 3, o escritório ia ler os 600 primeiros de 213.580 acórdãos. A ordem é do buscador, e não é amostra.

No nosso caso é igual: o site ordena da sentença mais recente, e na coleta-piloto as 20 primeiras eram todas de um dia só.

Na prática

Pegar a lista inteira do que a busca alcança e **sortear** dela as decisões a ler.

Duas formas de escolher

Por conveniência

os casos em que você atuou, os de um conhecido, os que o colega já tinha separado

não dá para saber o quanto se parecem com o resto (Lohr, cap. 15)

VS

Por sorteio

toda decisão da lista tem a mesma chance de entrar

a diferença entre amostra e lista passa a ser só acaso, e o acaso se mede

Quando comparar grupos

Se a pergunta compara atraso com cancelamento, e há poucos cancelamentos na lista, um sorteio simples pode trazer só um punhado deles.

Saída: separar a lista nos grupos que queremos comparar e sortear dentro de cada um.

Para pensar

Sorteio não corrige viés de seleção. Sortear das sentenças continua deixando de fora os processos parados.

Desenhem a coleta para a companhia

Em grupo, para uma das perguntas A, B ou C:

1. o universo e o cadastro
2. os termos (ou o assunto) e o período
3. o que fica de fora, e se isso muda a resposta
4. como sortear, e se é preciso separar grupos

Uma proposta para a pergunta A

RESPOSTA

Item	Proposta
Fonte	sentenças do TJSP de 1º grau
Busca	assunto 4829, que não depende da grafia
Período	o ano antes de 26/11/2025
Fora	acordos e processos sem sentença
Sorteio	separado para atraso e cancelamento

Viés de seleção

Viés de seleção

A forma de escolher os casos faz os escolhidos serem diferentes, de modo sistemático, do conjunto sobre o qual se quer concluir.

Mais casos escolhidos do mesmo jeito não corrigem: 10.749 decisões achadas por "remédio" continuam achadas por "remédio".

Na consulta 1, a seleção veio do termo, do réu, do ano, da instância e da tese. E no nosso caso?

Onde o viés mora

Distância	O que resolve
entre a amostra e o cadastro	o sorteio: o que sobra é acaso, e o acaso se mede
entre o cadastro e o universo	o sorteio não resolve: é aqui que mora o viés de seleção

Mudar a busca, juntar outra fonte, ou limitar a conclusão ao que o cadastro alcança (Lohr, seção 1.3).

Antes e depois da suspensão

Um colega compara a taxa de vitória dos passageiros em sentenças de antes de 26/11/2025 e de depois.

Depois, a taxa sobe. A diferença mede o efeito do Tema 1.417?

Não: depois, as sentenças são outras

RESPOSTA

Desde a suspensão, os processos que discutem as excludentes do art. 256, § 3º, do CBA estão parados. Os que continuam recebendo sentença são, em boa parte, os que a suspensão não alcança, como o fortuito interno.

A comparação põe lado a lado **populações diferentes**. Uma taxa maior depois pode vir só de quais casos chegam à sentença, e não de mudança no que os juízes decidem.

O mesmo defeito, duas perguntas

Pergunta	O que a busca em sentenças deixa de fora
C. Quanto a suspensão alcança	justamente os processos parados, que não têm sentença
A. Antes e depois	os casos com excludente, que pararam depois de 26/11/2025

Ler mais sentenças não conserta nenhum dos dois: o problema é **quais** chegam à fonte, e não quantas.

Dados pessoais na coleta

Dado pessoal e dado pessoal sensível

LGPD, art. 5º	O que é
Dado pessoal (I)	informação relacionada a pessoa natural identificada ou identificável
Dado pessoal sensível (II)	dado pessoal sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização religiosa, filosófica ou política, saúde, vida sexual, dado genético ou biométrico

Na nossa base

Na base de sentenças de atraso de voo, o que é dado pessoal, e o que é dado pessoal sensível?

O que guardar

RESPOSTA

Na sentença	É	Na base
nome do passageiro	pessoal	não guardar
número do processo	pessoal	só se precisar
"estava grávida"	sensível	no máximo "saúde: sim"
nome da companhia	não é pessoal	guardar

Guardar só o que a pergunta precisa

A LGPD pede que o tratamento se limite ao mínimo necessário para a finalidade (art. 6º, III).

Na prática da coleta: a pergunta decide as colunas, e o que não responde a pergunta nenhuma não entra na base.

O que sai desta aula

Hoje	Vira, na aula 25
as quatro perguntas	as colunas do codebook
o dado de cada pergunta	o tipo de cada coluna, e se sai por regex ou por modelo
a ficha da coleta e o sorteio	a base que vocês vão analisar nas aulas 26 e 27