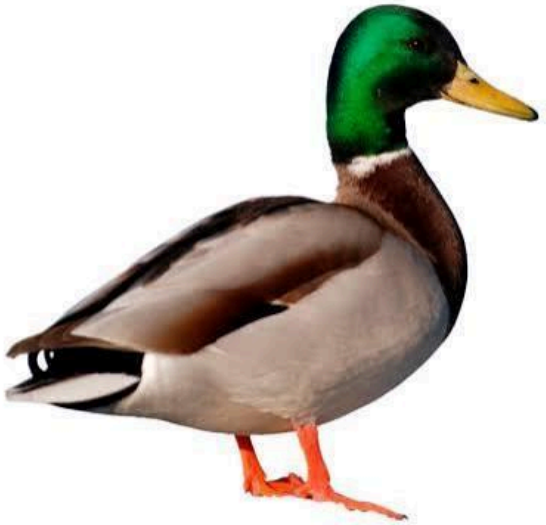
Ciência de Dados Aplicada ao Direito I

Aula 24

Viés de seleção e coleta



Prof. Bruno da Cunha de Oliveira - 2026/2

Os pareceres

Insper

Remédios contra planos no TJSP: contratar?

Na consulta	O que está escrito
O escritório	defende operadoras de planos e quer prever como o TJSP decide pedidos de medicamentos, inclusive nas liminares
A busca	"remédio", 1º grau do TJSP: 126.130; só 2025: 10.749
O título	Quando o TJSP joga dinheiro no lixo

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

Não contratar: pedir outra proposta

RESPOSTA

Na proposta	O problema
o termo "remédio"	entram o Estado e o "remédio processual"; sai o "medicamento"
só 2025 e só o 1º grau	conclui sobre "o TJSP" com um ano e sem as câmaras
o título já conclui	os casos são escolhidos para provar a tese
só sentenças	ficam fora as liminares, onde o custo aparece

Erro grosseiro no TCU: contratar?

Na consulta	O que está escrito
O escritório	defende gestores públicos, que só levam multa ou inabilitação com dolo ou erro grosseiro
A pergunta	como o TCU define "erro grosseiro" ao aplicar o art. 28 da LINDB
A busca	"LINDB" e "art. 28", acórdãos do Plenário, desde 26/04/2018: 729
O registro	uso do art. 28, enunciados, teses gerais, contradições

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

Contratar com mudanças

RESPOSTA

Na proposta	O problema
só o Plenário	as Câmaras também julgam gestores: o Plenário não é o TCU
busca por "art. 28"	sai quem diz "erro grosseiro" sem citar o artigo
729 decisões	quantas são do escopo? Ler uma amostra antes do preço
critérios abertos	não anotam a definição nem a punição

Despejo por falta de pagamento no TJSP: contratar?

Na consulta	O que está escrito
O escritório	atende uma administradora que precifica garantia de aluguel: tempo até a desocupação e quantas liminares saem
A busca	"despejo", acórdãos do TJSP, sem período: 213.580; analisa os 600 primeiros
O título	como decide o Tribunal
O registro	provimento, argumentos e tempo entre sentença e acórdão

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

Não contratar: pedir outra proposta

RESPOSTA

Na proposta	O problema
só acórdãos	só o despejo que teve recurso; o típico acaba no 1º grau, e o tempo sai maior
os 600 primeiros	a ordem é do buscador: não é amostra
o acórdão	não traz a desocupação nem a liminar, que estão no andamento do 1º grau
"despejo", sem data	pega o comercial, outros motivos e a pandemia

O STF no caso Master: contratar?

Na consulta	O que está escrito
O escritório	defende um investigado: como o STF se posiciona no caso?
O título	A perseguição ao STF no caso Master
A pergunta	como a mídia tem deturpado a imagem do STF com o caso Master
O material	a Pet 15556 e os correlatos que vierem; Folha, Estadão e O Globo; peças da PGR e decisões
Os autos	4 mil arquivos abertos em setembro; o resto segue em sigilo

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

Não contratar

RESPOSTA

Na proposta	O problema
pergunta e título	partem da conclusão, que nem é a do escritório
peças e decisões	4 mil arquivos abertos, sem critério do que ler; as diligências em curso seguem fechadas
três jornais	não são "a mídia"
um caso em curso	descreve o caso até uma data, não como o STF se posiciona

Nem todo defeito é viés de seleção

Defeito	O que fazer	Consultas
viés de seleção	mudar a forma de escolher, ou limitar a conclusão ao recorte	1, 2, 3, 4
tese a provar	pergunta descritiva, antes dos dados	1, 4
material que não responde	buscar o material que tem a resposta	1, 3, 4
casos demais	ler uma amostra sorteada	1, 2, 3

E se um modelo ler as 10.749?

Nas últimas aulas, um modelo de linguagem leu sentenças por nós. Com ele, a consulta 1 deixa de ter casos demais.

O que o modelo resolve na consulta 1, e o que continua igual?

O volume se resolve, a seleção não

RESPOSTA

O modelo resolve	Continua igual
ler todas as 10.749	as 10.749 vieram do termo "remédio", de 2025 e do 1º grau
extrair os campos de cada uma	a tese no título, que escolheu os casos

E o que o modelo extrai ainda se confere numa amostra lida por nós.

De volta à companhia

Insper

Contar as ações paradas

A companhia quer saber quantas ações dela estão paradas pela suspensão do Tema 1.417.

Um colega propõe: baixar as sentenças do TJSP com "atraso de voo" e contar.

> O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

A busca em sentenças não alcança quem parou antes dela

RESPOSTA

Na proposta do colega	O que acontece
Dentro	os processos que já chegaram à sentença
Fora	os que a suspensão parou antes dela, que são os que a companhia quer contar
A diferença	quem ficou fora é justamente quem a pergunta procura

Para contá-los, partir dos processos distribuídos e ainda sem sentença.

A nossa proposta à companhia aérea

O Tema 1.417, como o caso Master, ainda corre no STF.

Que pergunta a nossa proposta à companhia pode responder com dados, e qual ela não pode?

O que os dados respondem

RESPOSTA

Os dados	A pergunta
Não respondem	o que o STF vai decidir
Respondem	o que os processos já decididos dizem do risco da companhia, e quantos estão parados, por qual motivo de atraso

As perguntas de vocês

As perguntas que vamos responder

Pergunta	O que quer saber
A. Quanto o passageiro ganha	a taxa de vitória, no geral e por recorte: período, atraso ou cancelamento, valor
B. Com qual fundamento	que argumento e que lei decidem: CDC, CBA, excludentes
C. Quanto a suspensão alcança	quantas ações o Tema 1.417 parou
D. O que muda o resultado	como a taxa varia com cada característica

A pergunta D, com cuidado

"Quais variáveis **afetam** o resultado?" pergunta por causa.

O que uma base de sentenças mostra é **como a taxa varia** junto com cada característica: em cancelamento, ganha-se mais do que em atraso?

Importante

Descrever que duas coisas andam juntas é o que esta disciplina faz. Dizer que uma causa a outra fica para a CDAD-2.

Que dado, e onde ele está?

Para responder cada uma das quatro, que dado precisamos ter em mãos, e onde ele está?

Dado é fato sobre o mundo, obtido por observação.

O dado de cada pergunta

RESPOSTA

	Dado
A	resultado, data, atraso ou cancelamento, valor da causa
B	lei aplicada, excludente alegada, se foi aceita
C	processos parados e o motivo do atraso
D	tudo o que está acima, junto

A fonte de cada dado

RESPOSTA

Dado	Fonte
resultado, fundamento, excludente	texto da sentença
data, vara, companhia	dados da busca de sentenças
valor da causa	consulta do processo, e não a sentença
processos parados	processos distribuídos e ainda sem sentença

Sentenças com "atraso de voo" no TJSP

No ano anterior à suspensão (27/11/2024 a 26/11/2025), a busca de sentenças do TJSP pela expressão "atraso de voo" devolve 15.975.

E nos onze meses seguintes (27/11/2025 a 02/11/2026)?

De 15.975 para 1.495

RESPOSTA

Busca no TJSP, 1º grau	Antes	Depois
"atraso de voo"	15.975	1.495
"cancelamento do voo"	18.087	1.510
"Tema 1417" ou "1.560.244"	1	1.153

Contagem do juscraper em 02/11/2026. A queda não diz sozinha quantas ações a suspensão parou: o termo de busca, o período e o que conta como sentença mudam o número.

Olhar uma parte para entender o todo

Na fonte, queremos tudo?

Só a busca por "atraso de voo" nas sentenças do TJSP de 1º grau devolve 15.975 decisões, num ano.

Ler, baixar e conferir tudo isso custa caro. E, para as perguntas A e B, não é preciso.

Amostra: uma parte, escolhida para falar do todo

1. o exame de sangue tira um tubo, e não o sangue todo
2. a pesquisa eleitoral ouve uns 2 mil eleitores, e não 150 milhões
3. a cozinheira prova uma colher, desde que tenha mexido a panela

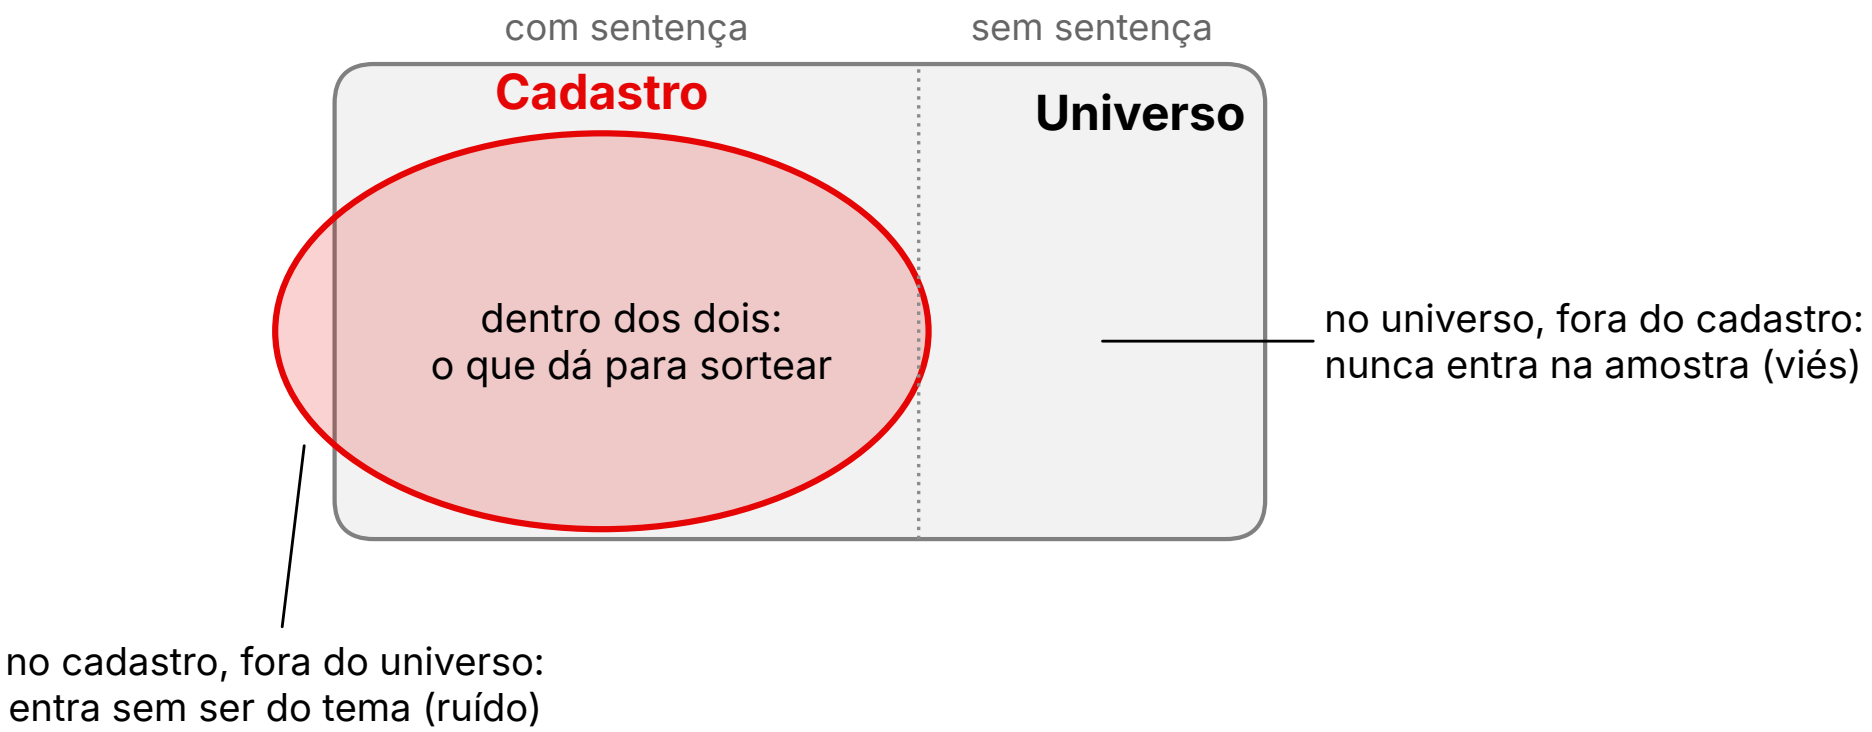
A colher só diz algo da panela se a panela foi mexida: é o sorteio que garante isso.

Universo, cadastro e amostra

Conjunto	No nosso caso
Universo	todas as ações de passageiros contra companhias aéreas por atraso ou cancelamento
Cadastro amostral	a lista que conseguimos montar: o que o buscador do TJSP devolve
Amostra	as decisões que sorteamos dessa lista e lemos

A amostra sai do cadastro, e não do universo (Lohr, cap. 1).

O cadastro e o universo



Uma boa busca aumenta o miolo: alcança mais do universo e traz menos do que não é do tema.

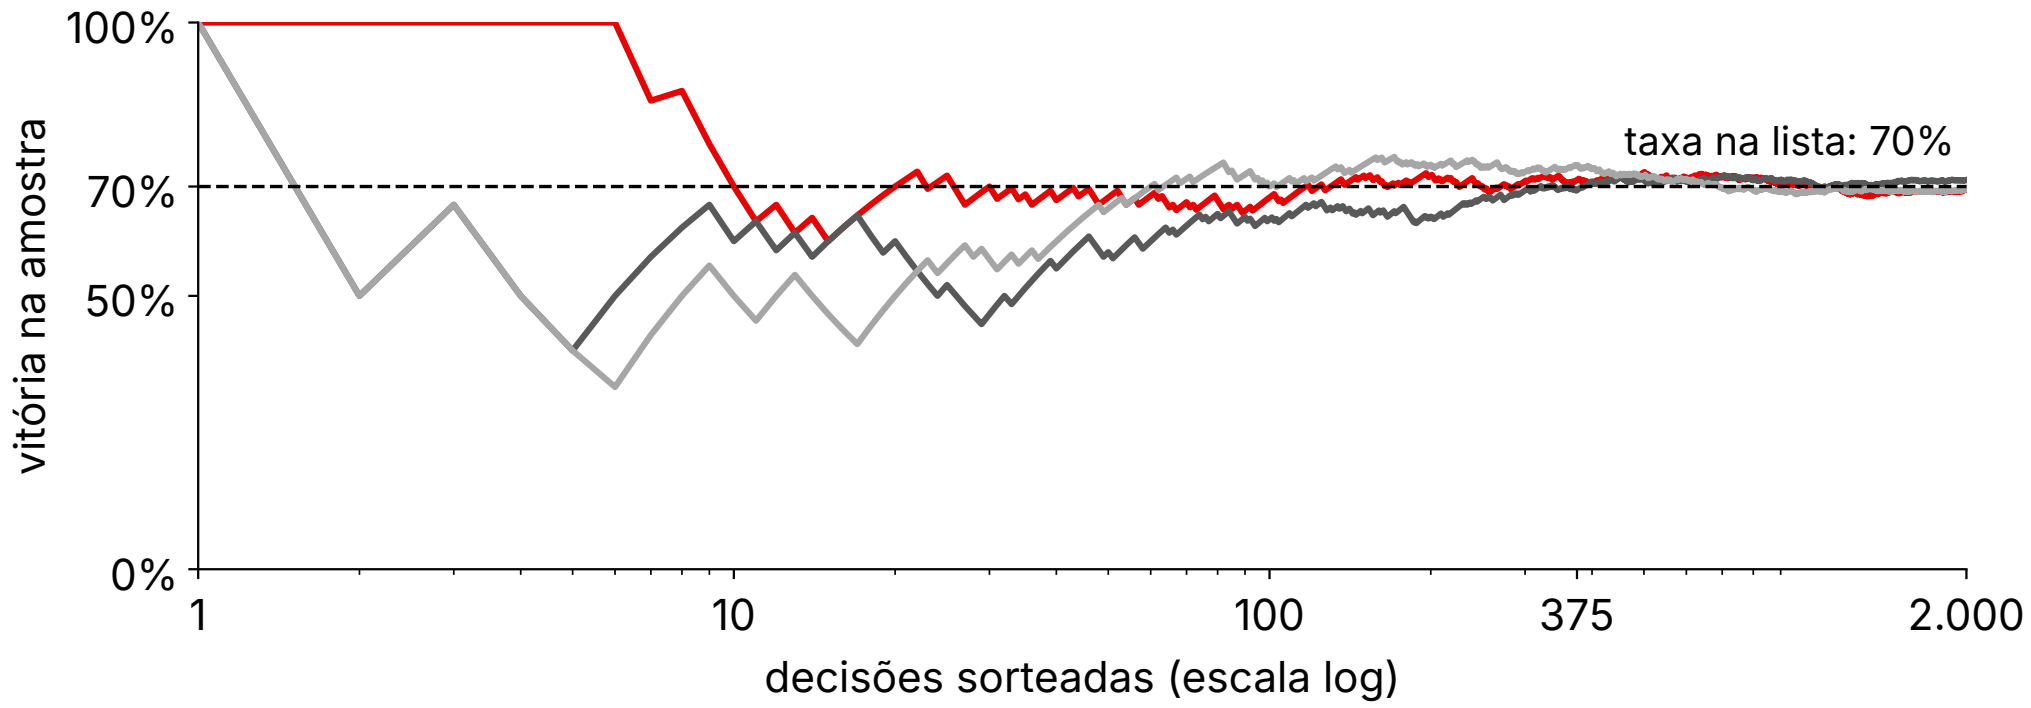
Amostra aleatória

Amostra aleatória: toda decisão da lista tem a mesma chance de ser sorteada.

Com isso, a diferença entre a amostra e a lista deixa de depender de quem escolheu. Ela passa a ser acaso.

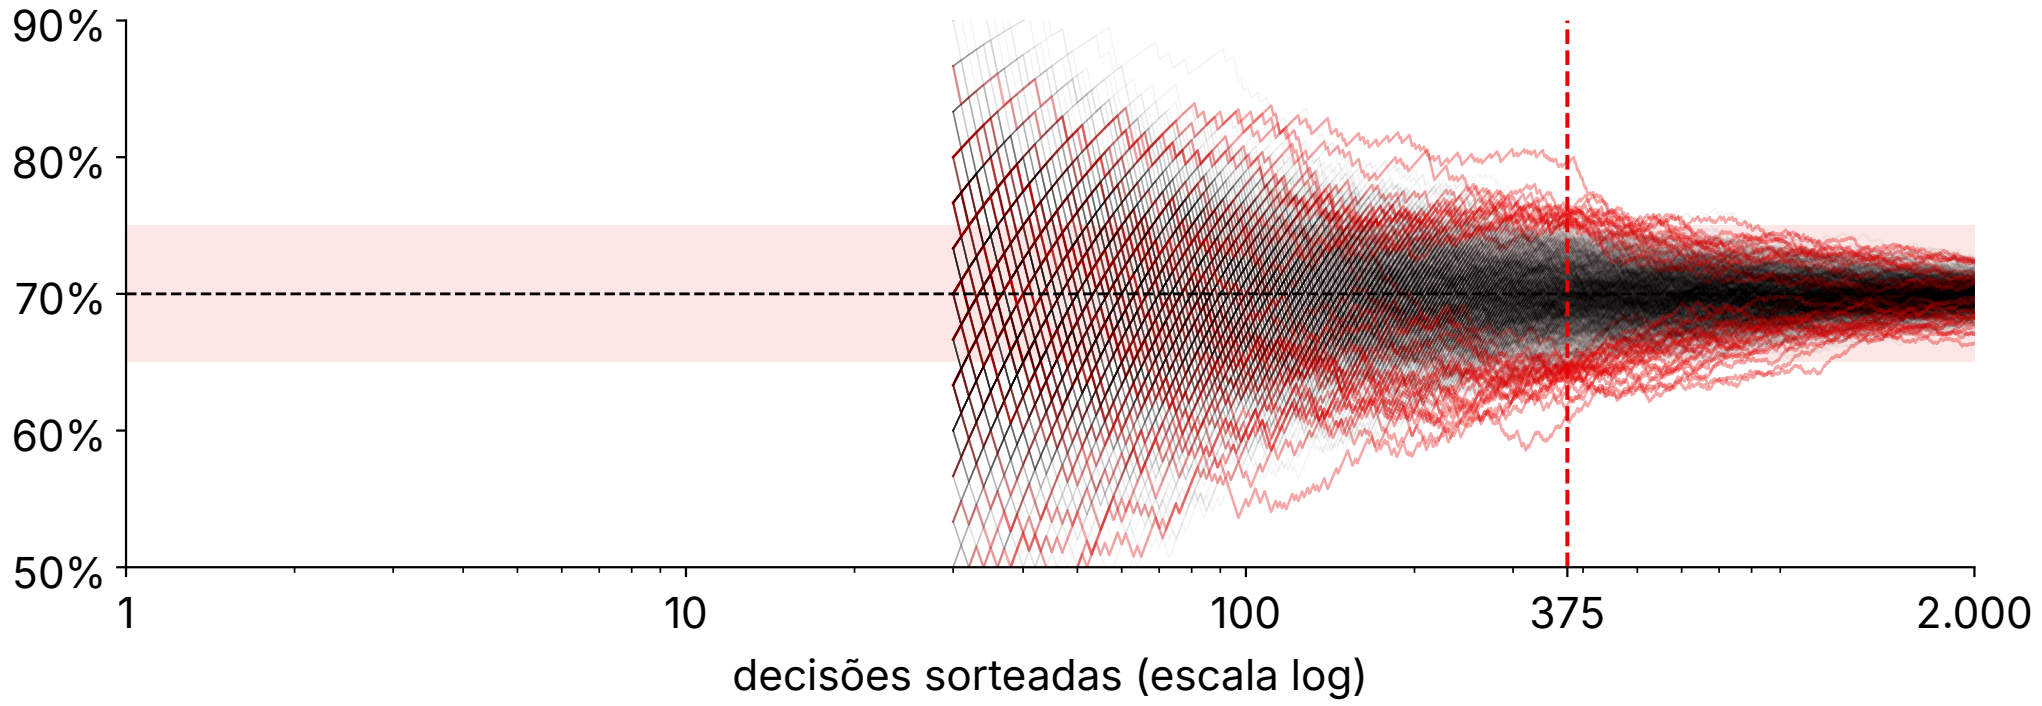
E o acaso tem regra: quanto maior a amostra sorteada, menor ele fica.

Lei dos grandes números



Três sorteios simulados de uma lista em que o passageiro ganha 70%. A taxa converge para a da lista, e não para a do universo.

Mil sorteios da mesma lista



Mil sorteios de 2.000 decisões cada, da lista de 15.975 (70% de vitória). Com 375 sorteadas, 959 ficam a até 5 pontos dos 70%; em vermelho, os que ficam fora.

A amostra quase não cresce com o todo

Decisões na lista	Amostra, erro de 5 pontos	Amostra, erro de 2 pontos
1.000	278	706
15.975	375	2.087
100.000	383	2.345
1.000.000	384	2.395

Para estimar uma taxa, como a de vitória, com 95% de confiança e amostra sorteada.

Quanto custa ler: gente

10 min por sentença, hora a R$ 800	Tudo	Erro de 2 pontos	Erro de 5 pontos
sentenças	15.975	2.087	375
horas	2.663	348	63
custo	R$ 2,1 milhões	R$ 278 mil	R$ 50 mil

Nenhum cliente paga R$ 2 milhões para saber uma taxa que 375 decisões estimam com 5 pontos de erro.

Quanto custa ler: modelo de linguagem

GPT-5.6 Luna, 5.000 tokens de entrada e 500 de saída	Tudo	Erro de 2 pontos	Erro de 5 pontos
sentenças	15.975	2.087	375
tokens	88 milhões	11 milhões	2 milhões
custo	US$ 128	US$ 17	US$ 3

Ler tudo com o modelo custa menos que uma hora de advogado. O que custa é conferir: o que ele extrai se confere numa amostra lida por gente.

E se a pergunta for sobre o Brasil?

GPT-5.6 Luna	Ações	Só a sentença	Autos inteiros
TJSP, 2025, "atraso de voo"	15.975	US$ 128	US$ 863
Brasil, 2020 a 2025 (estimativa)	1,25 milhão	US$ 10 mil	US$ 68 mil

No TJSP de 2025, ler tudo com o modelo compensa. No Brasil inteiro, lendo os autos, a conta já pesa.

O que o preço do modelo não mostra

1. **coletar**: 27 tribunais de justiça, cada um com seu site; nem todo tem raspador, e alguns barram robôs
2. **chegar aos autos**: a sentença é pública na busca, a petição inicial nem sempre
3. **conferir**: o que o modelo extrai se confere lendo uma amostra, com ou sem modelo
4. **esperar**: baixar 1 milhão de processos leva semanas, e o cliente quer a resposta antes

A amostra não é só para economizar leitura: é para caber no tempo, na coleta e na conferência.

Antes de sortear, três decisões

1. **de onde** sortear: o cadastro, e quanto ele cobre do universo
2. **como** sortear: tirar da lista inteira, e não pegar as primeiras
3. **quantas** ler: já vimos, a amostra quase não cresce com o todo

De onde sortear: a lista

O cadastro não é o universo

O universo quase nunca está ao nosso alcance. O que alcançamos é uma lista, e ela tem buracos:

1. processos em segredo de justiça não aparecem na busca
2. processos sem sentença não estão numa busca de sentenças
3. a sentença que não usa as palavras buscadas fica de fora

O buscador do TJSP deve cobrir boa parte dos casos. A pergunta é sempre: o que ficou fora é diferente do que ficou dentro?

Outro cadastro: o DataJud

	Busca de sentenças do TJSP	DataJud (CNJ)
O que lista	sentenças publicadas	processos, com classe, assunto e movimentos
Sem sentença	não alcança	alcança, inclusive os suspensos
Como buscar	palavra, assunto, classe	assunto e classe, sem palavra-chave
Período	o do buscador	a partir de 2020
Texto	traz a sentença	não traz: só metadados

Qual cadastro? Depende da pergunta

Pergunta	Cadastro
A. Quanto o passageiro ganha	sentenças do TJSP: o resultado está no texto
B. Com qual fundamento	sentenças do TJSP: o fundamento está no texto
C. Quanto a suspensão alcança	DataJud: lista os processos parados, que não têm sentença

Os dois se juntam pelo número do processo: o DataJud dá a lista, e o raspador do TJSP busca o andamento e as decisões de cada processo sorteado.

O preço de partir do DataJud

1. sem palavra-chave, o assunto traz também o que não é atraso nem cancelamento de voo
2. quanto do assunto é de fato relevante? Só lendo uma amostra para estimar
3. antes de 2020 não há dados
4. cada processo sorteado pede uma consulta a mais no TJSP

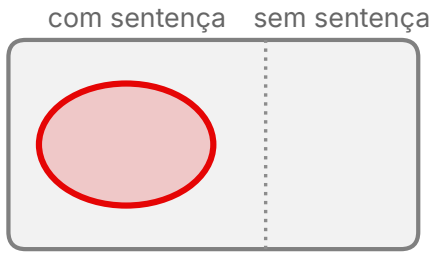
Mais caro de montar, mas é o único dos dois que enxerga quem parou antes da sentença.

Cada escolha muda a lista

Escolha	Na coleta-piloto
"atraso de voo", com aspas	15.975
sem aspas	34.503: as palavras se ligam com E
com acento ("vôo")	12.898
assunto 4829	21.867
o que o termo pega	das 20 primeiras, 5 fora do ramo aéreo

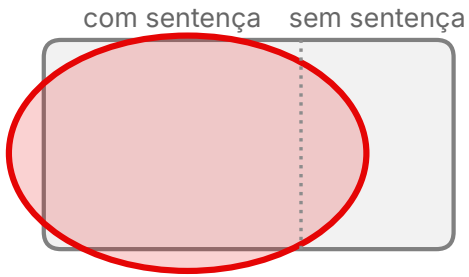
Cada busca, um cadastro diferente

"atraso de voo", com aspas



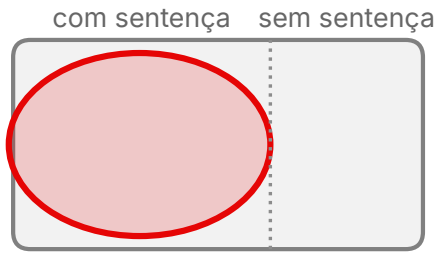
quase só do tema,
mas deixa muito de fora

sem aspas



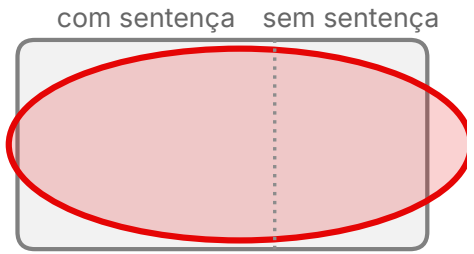
pega mais,
e muito fora do tema

assunto 4829



não depende da grafia,
traz algum ruído

DataJud, por assunto



alcança quem não tem
sentença; só desde 2020

Cinza: o universo. Vermelho: o que a busca devolve. Esquema, sem escala.

Cobertura é quanto do cinza o vermelho alcança. Precisão é quanto do vermelho cai no cinza.

Insper

A ficha da coleta

Antes de baixar qualquer coisa, anotar:

1. tribunal e grau (TJSP de 1º ou de 2º grau, STJ, STF)
2. termos exatos, com aspas e variações, ou assunto e classe
3. período, e por que ele
4. o que conta como decisão (sentença, acórdão, liminar)
5. data e hora da busca, e quantas decisões ela devolveu

Quem repetir a busca tem que chegar ao mesmo cadastro.

Como sortear

Como na consulta 3: as primeiras não são amostra

Na consulta 3, o escritório ia ler os 600 primeiros de 213.580 acórdãos. A ordem é do buscador, e não é amostra.

No nosso caso é igual: o site ordena da sentença mais recente, e na coleta-piloto as 20 primeiras eram todas de um dia só.

Na prática

Pegar a lista inteira do que a busca alcança e **sortear** dela as decisões a ler.

Duas formas de escolher

Por conveniência		Por sorteio
os casos em que você atuou, os de um conhecido, os que o colega já tinha separado	VS	toda decisão da lista tem a mesma chance de entrar
não dá para saber o quanto se parecem com o resto (Lohr, cap. 15)		a diferença entre amostra e lista passa a ser só acaso, e o acaso se mede

Quando comparar grupos

Se a pergunta compara atraso com cancelamento, e há poucos cancelamentos na lista, um sorteio simples pode trazer só um punhado deles.

Saída: separar a lista nos grupos que queremos comparar e sortear dentro de cada um.

Para pensar

Sorteio não corrige viés de seleção. Sortear das sentenças continua deixando de fora os processos parados.

Desenhem a coleta para a companhia

Em grupo, para uma das perguntas A, B ou C:

1. o universo e o cadastro
2. os termos (ou o assunto) e o período
3. o que fica de fora, e se isso muda a resposta
4. como sortear, e se é preciso separar grupos

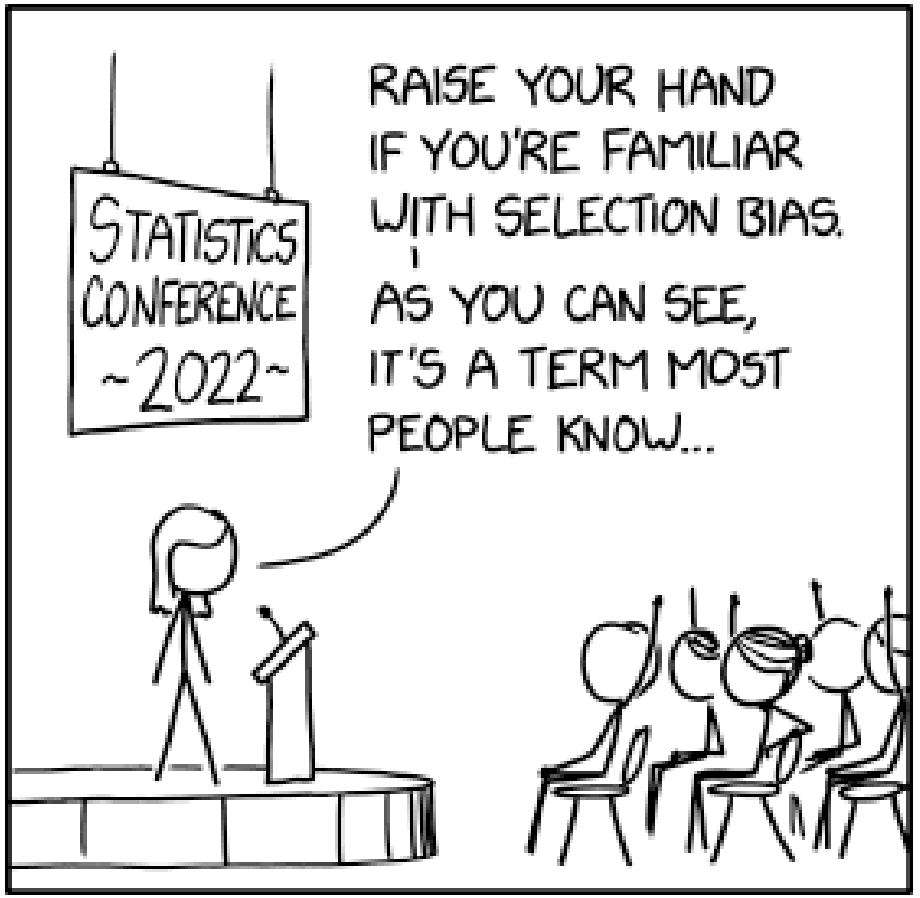
Uma proposta para a pergunta A

RESPOSTA

Item	Proposta
Cadastro	sentenças do TJSP de 1º grau
Busca	assunto 4829, que não depende da grafia
Período	o ano antes de 26/11/2025
Fora	acordos e processos sem sentença
Sorteio	separado para atraso e cancelamento

Viés de seleção

Quem levanta a mão?



xkcd 2618, “Selection Bias”, de Randall Munroe (xkcd.com/2618), licença CC BY-NC 2.5.

Insper

Uma pesquisa por e-mail

Uma empresa mandou por e-mail uma pesquisa a todos os clientes.

95% dos que responderam dizem que gostam de responder pesquisas.

O que esse número diz sobre os clientes da empresa?

Quem respondeu se escolheu

Só responde pesquisa quem gosta de responder pesquisa. Quem não gosta apagou o e-mail.

A amostra se escolheu sozinha: é a autosseleção. Os 95% falam de quem respondeu, e não dos clientes.

Mais respostas não ajudam: mil respostas a mais vêm do mesmo jeito, de quem gosta de responder.

Viés de seleção

A forma de escolher os casos faz os escolhidos serem diferentes, de modo sistemático, do conjunto sobre o qual se quer concluir.

Mais casos escolhidos do mesmo jeito não corrigem: 10.749 decisões achadas por "remédio" continuam achadas por "remédio".

Na consulta 1, a seleção veio do termo, do réu, do ano, da instância e da tese. E no nosso caso?

O mesmo defeito, vários caminhos

Caminho	Como acontece	No direito
autosseleção	o próprio caso escolhe entrar	só vira processo quem decide processar
sobrevivência	só sobra quem passou por um filtro	só o despejo com recurso chega ao acórdão (consulta 3)
cobertura	o cadastro não alcança parte do universo	a busca de sentenças não vê os processos parados
não resposta	o sorteado não chega até nós	processo em segredo, autos que não abrem

Em todos, a pergunta é a mesma: o que ficou fora é diferente do que ficou dentro?

Onde o viés mora

Distância	O que resolve
entre a amostra e o cadastro	o sorteio: o que sobra é acaso, e o acaso se mede
entre o cadastro e o universo	o sorteio não resolve: é aqui que mora o viés de seleção

Mudar a busca, juntar outra fonte, ou limitar a conclusão ao que o cadastro alcança (Lohr, seção 1.3).

Antes e depois da suspensão

Um colega compara a taxa de vitória dos passageiros em sentenças de antes de 26/11/2025 e de depois.

Depois, a taxa sobe. A diferença mede o efeito do Tema 1.417?

Não: depois, as sentenças são outras

RESPOSTA

Desde a suspensão, os processos que discutem as excludentes do art. 256, § 3º, do CBA estão parados. Os que continuam recebendo sentença são, em boa parte, os que a suspensão não alcança, como o fortuito interno.

A comparação põe lado a lado **populações diferentes**. Uma taxa maior depois pode vir só de quais casos chegam à sentença, e não de mudança no que os juízes decidem.

O mesmo defeito, duas perguntas

Pergunta	O que a busca em sentenças deixa de fora
C. Quanto a suspensão alcança	justamente os processos parados, que não têm sentença
Antes e depois	os casos com excludente, que pararam depois de 26/11/2025

Ler mais sentenças não conserta nenhum dos dois: o problema é **quais** chegam à fonte, e não quantas.

Dados pessoais na coleta

Dado pessoal e dado pessoal sensível

LGPD, art. 5º	O que é
Dado pessoal (I)	informação relacionada a pessoa natural identificada ou identificável
Dado pessoal sensível (II)	dado pessoal sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização religiosa, filosófica ou política, saúde, vida sexual, dado genético ou biométrico

Na nossa base

Na base de sentenças de atraso de voo, o que é dado pessoal, e o que é dado pessoal sensível?

O que guardar

RESPOSTA

Na sentença	É	Na base
nome do passageiro	pessoal	não guardar
número do processo	pessoal	só se precisar
"estava grávida"	sensível	no máximo "saúde: sim"
nome da companhia	não é pessoal	guardar

Guardar só o que a pergunta precisa

A LGPD pede que o tratamento se limite ao mínimo necessário para a finalidade (art. 6º, III).

Na prática da coleta: a pergunta decide as colunas, e o que não responde a pergunta nenhuma não entra na base.