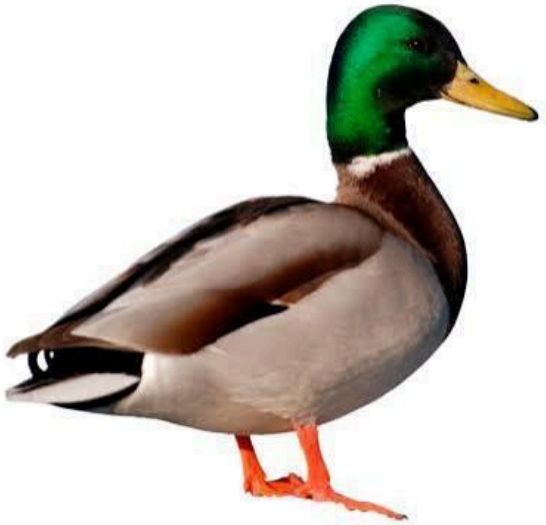
# Ciência de Dados Aplicada ao Direito I

## Aula 24

Viés de seleção e coleta



Prof. Bruno da Cunha de Oliveira - 2026/2

# Os pareceres

Insper

# Remédios contra planos no TJSP: contratar?

| Na consulta | O que está escrito |
|---|---|
| **O escritório** | defende operadoras de planos e quer prever como o TJSP decide pedidos de medicamentos, inclusive nas liminares |
| **A busca** | "remédio", 1º grau do TJSP: 126.130; só 2025: 10.749 |
| **O título** | Quando o TJSP joga dinheiro no lixo |

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

# Não contratar: pedir outra proposta

**RESPOSTA**

| Na proposta | O problema |
|---|---|
| o termo "remédio" | entram o Estado e o "remédio processual"; sai o "medicamento" |
| só 2025 e só o 1º grau | conclui sobre "o TJSP" com um ano e sem as câmaras |
| o título já conclui | os casos são escolhidos para provar a tese |
| só sentenças | ficam fora as liminares, onde o custo aparece |

# Erro grosseiro no TCU: contratar?

| Na consulta | O que está escrito |
|---|---|
| **O escritório** | defende gestores públicos, que só levam multa ou inabilitação com dolo ou erro grosseiro |
| **A pergunta** | como o TCU define "erro grosseiro" ao aplicar o art. 28 da LINDB |
| **A busca** | "LINDB" e "art. 28", acórdãos do Plenário, desde 26/04/2018: 729 |
| **O registro** | uso do art. 28, enunciados, teses gerais, contradições |

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

# Contratar com mudanças

**RESPOSTA**

| Na proposta | O problema |
|---|---|
| só o Plenário | as Câmaras também julgam gestores: o Plenário não é o TCU |
| busca por "art. 28" | sai quem diz "erro grosseiro" sem citar o artigo |
| 729 decisões | quantas são do escopo? Ler uma amostra antes do preço |
| critérios abertos | não anotam a definição nem a punição |

# Despejo por falta de pagamento no TJSP: contratar?

| Na consulta | O que está escrito |
|---|---|
| **O escritório** | atende uma administradora que precifica garantia de aluguel: tempo até a desocupação e quantas liminares saem |
| **A busca** | "despejo", acórdãos do TJSP, sem período: 213.580; analisa os 600 primeiros |
| **O título** | como decide o Tribunal |
| **O registro** | provimento, argumentos e tempo entre sentença e acórdão |

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

# Não contratar: pedir outra proposta

**RESPOSTA**

| Na proposta | O problema |
|---|---|
| só acórdãos | só o despejo que teve recurso; o típico acaba no 1º grau, e o tempo sai maior |
| os 600 primeiros | a ordem é do buscador: não é amostra |
| o acórdão | não traz a desocupação nem a liminar, que estão no andamento do 1º grau |
| "despejo", sem data | pega o comercial, outros motivos e a pandemia |

# O STF no caso Master: contratar?

| Na consulta | O que está escrito |
|---|---|
| **O escritório** | defende um investigado: como o STF se posiciona no caso? |
| **O título** | A perseguição ao STF no caso Master |
| **A pergunta** | como a mídia tem deturpado a imagem do STF com o caso Master |
| **O material** | a Pet 15556 e os correlatos que vierem; Folha, Estadão e O Globo; peças da PGR e decisões |
| **Os autos** | 4 mil arquivos abertos em setembro; o resto segue em sigilo |

O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

# Não contratar

**RESPOSTA**

| Na proposta | O problema |
|---|---|
| pergunta e título | partem da conclusão, que nem é a do escritório |
| peças e decisões | 4 mil arquivos abertos, sem critério do que ler; as diligências em curso seguem fechadas |
| três jornais | não são "a mídia" |
| um caso em curso | descreve o caso até uma data, não como o STF se posiciona |

# Nem todo defeito é viés de seleção

| Defeito | O que fazer | Consultas |
|---|---|---|
| viés de seleção | mudar a forma de escolher, ou limitar a conclusão ao recorte | 1, 2, 3, 4 |
| tese a provar | pergunta descritiva, antes dos dados | 1, 4 |
| material que não responde | buscar o material que tem a resposta | 1, 3, 4 |
| casos demais | ler uma amostra sorteada | 1, 2, 3 |

# E se um modelo ler as 10.749?

Nas últimas aulas, um modelo de linguagem leu sentenças por nós. Com ele, a consulta 1 deixa de ter casos demais.

O que o modelo resolve na consulta 1, e o que continua igual?

# O volume se resolve, a seleção não

**RESPOSTA**

| O modelo resolve | Continua igual |
|---|---|
| ler todas as 10.749 | as 10.749 vieram do termo "remédio", de 2025 e do 1º grau |
| extrair os campos de cada uma | a tese no título, que escolheu os casos |

E o que o modelo extrai ainda se confere numa amostra lida por nós.

# De volta à companhia

Insper

# Contar as ações paradas

A companhia quer saber quantas ações dela estão paradas pela suspensão do Tema 1.417.

Um colega propõe: baixar as sentenças do TJSP com "atraso de voo" e contar.

> O que ficou dentro, o que ficou fora, e o que ficou fora é diferente do que ficou dentro?

# A busca em sentenças não alcança quem parou antes dela

**RESPOSTA**

| Na proposta do colega | O que acontece |
|---|---|
| **Dentro** | os processos que já chegaram à sentença |
| **Fora** | os que a suspensão parou antes dela, que são os que a companhia quer contar |
| **A diferença** | quem ficou fora é justamente quem a pergunta procura |

Para contá-los, partir dos processos distribuídos e ainda sem sentença.

# A nossa proposta à companhia aérea

O Tema 1.417, como o caso Master, ainda corre no STF.

Que pergunta a nossa proposta à companhia pode responder com dados, e qual ela não pode?

# O que os dados respondem

**RESPOSTA**

| Os dados | A pergunta |
|---|---|
| **Não respondem** | o que o STF vai decidir |
| **Respondem** | o que os processos já decididos dizem do risco da companhia, e quantos estão parados, por qual motivo de atraso |

# As perguntas de vocês

# As perguntas que vamos responder

| Pergunta | O que quer saber |
|---|---|
| A. Quanto o passageiro ganha | a taxa de vitória, no geral e por recorte: período, atraso ou cancelamento, valor |
| B. Com qual fundamento | que argumento e que lei decidem: CDC, CBA, excludentes |
| C. Quanto a suspensão alcança | quantas ações o Tema 1.417 parou |
| D. O que muda o resultado | como a taxa varia com cada característica |

# A pergunta D, com cuidado

"Quais variáveis **afetam** o resultado?" pergunta por causa.

O que uma base de sentenças mostra é **como a taxa varia** junto com cada característica: em cancelamento, ganha-se mais do que em atraso?

**Importante**

Descrever que duas coisas andam juntas é o que esta disciplina faz. Dizer que uma causa a outra fica para a CDAD-2.

# Primeiro: que dado?

Para responder cada uma das quatro, que dado precisamos ter em mãos?

Dado é fato sobre o mundo, obtido por observação.

# O dado de cada pergunta

**RESPOSTA**

| | Dado |
|---|---|
| A | resultado, data, atraso ou cancelamento, valor da causa |
| B | lei aplicada, excludente alegada, se foi aceita |
| C | processos parados e o motivo do atraso |
| D | tudo o que está acima, junto |

# Depois: onde está esse dado?

Onde encontramos cada um desses dados?

# A fonte de cada dado

**RESPOSTA**

| Dado | Fonte |
|---|---|
| resultado, fundamento, excludente | texto da sentença |
| data, vara, companhia | dados da busca de sentenças |
| valor da causa | consulta do processo, e não a sentença |
| processos parados | processos distribuídos e ainda sem sentença |

# Olhar uma parte para entender o todo

# Na fonte, queremos tudo?

Só a busca por "atraso de voo" nas sentenças do TJSP de 1º grau devolve 15.975 decisões, num ano.

Ler, baixar e conferir tudo isso custa caro. E, para as perguntas A e B, não é preciso.

# Amostra: uma parte, escolhida para falar do todo

1. o exame de sangue tira um tubo, e não o sangue todo
2. a pesquisa eleitoral ouve uns 2 mil eleitores, e não 150 milhões
3. a cozinheira prova uma colher, desde que tenha mexido a panela

A colher só diz algo da panela se a panela foi mexida: é o sorteio que garante isso.

# A amostra quase não cresce com o todo

| Decisões na lista | Amostra, erro de 5 pontos | Amostra, erro de 2 pontos |
|---|---|---|
| 1.000 | 278 | 706 |
| 15.975 | 375 | 2.087 |
| 100.000 | 383 | 2.345 |
| 1.000.000 | 384 | 2.395 |

Para estimar uma taxa, como a de vitória, com 95% de confiança e amostra sorteada.

# Quanto custa ler: gente

| 10 min por sentença, hora a R$ 800 | Tudo | Erro de 2 pontos | Erro de 5 pontos |
|---|---|---|---|
| sentenças | 15.975 | 2.087 | 375 |
| horas | 2.663 | 348 | 63 |
| custo | R$ 2,1 milhões | R$ 278 mil | R$ 50 mil |

Nenhum cliente paga R$ 2 milhões para saber uma taxa que 375 decisões estimam com 5 pontos de erro.

# Quanto custa ler: modelo de linguagem

| GPT-5.6 Luna, 5.000 tokens de entrada e 500 de saída | Tudo | Erro de 2 pontos | Erro de 5 pontos |
|---|---|---|---|
| sentenças | 15.975 | 2.087 | 375 |
| tokens | 88 milhões | 11 milhões | 2 milhões |
| custo | US$ 128 | US$ 17 | US$ 3 |

Ler tudo com o modelo custa menos que uma hora de advogado. O que custa é conferir: o que ele extrai se confere numa amostra lida por gente.

# E se o universo for o Brasil?

| GPT-5.6 Luna | Ações | Só a sentença | Autos inteiros |
|---|---|---|---|
| TJSP, 2025, "atraso de voo" | 15.975 | US$ 128 | US$ 863 |
| Brasil, 2020 a 2025 (estimativa) | 1,25 milhão | US$ 10 mil | US$ 68 mil |

No TJSP de 2025, ler tudo com o modelo compensa. No Brasil inteiro, lendo os autos, a conta já pesa.

# O que o preço do modelo não mostra

1. **coletar**: 27 tribunais de justiça, cada um com seu site; nem todo tem raspador, e alguns barram robôs
2. **chegar aos autos**: a sentença é pública na busca, a petição inicial nem sempre
3. **conferir**: o que o modelo extrai se confere lendo uma amostra, com ou sem modelo
4. **esperar**: baixar 1 milhão de processos leva semanas, e o cliente quer a resposta antes

A amostra não é só para economizar leitura: é para caber no tempo, na coleta e na conferência.

# Antes de sortear, três decisões

1. **de onde** sortear: a lista que conseguimos montar, e quanto ela cobre do todo
2. **como** sortear: tirar da lista inteira, e não pegar as primeiras
3. **quantas** ler: o tamanho que a pergunta e o tempo permitem

# De onde sortear: a lista

# Universo, cadastro e amostra

| Conjunto | No nosso caso |
|---|---|
| Universo | todas as ações de passageiros contra companhias aéreas por atraso ou cancelamento |
| Cadastro amostral | a lista que conseguimos montar: o que o buscador do TJSP devolve |
| Amostra | as decisões que sorteamos dessa lista e lemos |

A amostra sai do cadastro, e não do universo (Lohr, cap. 1).

# O cadastro não é o universo

O universo quase nunca está ao nosso alcance. O que alcançamos é uma lista, e ela tem buracos:

1. processos em segredo de justiça não aparecem na busca
2. processos sem sentença não estão numa busca de sentenças
3. a sentença que não usa as palavras buscadas fica de fora

O buscador do TJSP deve cobrir boa parte dos casos. A pergunta é sempre: o que ficou fora é diferente do que ficou dentro?

# Outro cadastro: o DataJud

| | Busca de sentenças do TJSP | DataJud (CNJ) |
|---|---|---|
| O que lista | sentenças publicadas | processos, com classe, assunto e movimentos |
| Sem sentença | não alcança | alcança, inclusive os suspensos |
| Como buscar | palavra, assunto, classe | assunto e classe, sem palavra-chave |
| Período | o do buscador | a partir de 2020 |
| Texto | traz a sentença | não traz: só metadados |

# Qual cadastro? Depende da pergunta

| Pergunta | Cadastro |
|---|---|
| A. Quanto o passageiro ganha | sentenças do TJSP: o resultado está no texto |
| B. Com qual fundamento | sentenças do TJSP: o fundamento está no texto |
| C. Quanto a suspensão alcança | DataJud: lista os processos parados, que não têm sentença |

Os dois se juntam pelo número do processo: o DataJud dá a lista, e o raspador do TJSP busca o andamento e as decisões de cada processo sorteado.

# O preço de partir do DataJud

1. sem palavra-chave, o assunto traz também o que não é atraso nem cancelamento de voo
2. quanto do assunto é de fato relevante? Só lendo uma amostra para estimar
3. antes de 2020 não há dados
4. cada processo sorteado pede uma consulta a mais no TJSP

Mais caro de montar, mas é o único dos dois que enxerga quem parou antes da sentença.

# Que busca vocês fariam?

Em grupo: montem a busca no TJSP que gera a lista das ações de atraso e cancelamento de voo.

1. qual cadastro: busca de sentenças do TJSP ou DataJud
2. 1º grau, 2º grau, ou os dois
3. termo livre (quais palavras, com ou sem aspas), assunto ou classe
4. que período
5. o que a busca de vocês deixa de fora

# Sentenças com "atraso de voo" no TJSP

No ano anterior à suspensão (27/11/2024 a 26/11/2025), a busca de sentenças do TJSP pela expressão "atraso de voo" devolve 15.975.

E nos onze meses seguintes (27/11/2025 a 02/11/2026)?

# De 15.975 para 1.495

**RESPOSTA**

| Busca no TJSP, 1º grau | Antes | Depois |
|---|---|---|
| "atraso de voo" | 15.975 | 1.495 |
| "cancelamento do voo" | 18.087 | 1.510 |
| "Tema 1417" ou "1.560.244" | 1 | 1.153 |

Contagem do juscraper em 02/11/2026. A queda não diz sozinha quantas ações a suspensão parou: o termo de busca, o período e o que conta como sentença mudam o número.

# Cada escolha muda a lista

**RESPOSTA**

| Escolha | Na coleta-piloto |
|---|---|
| "atraso de voo", com aspas | 15.975 |
| sem aspas | 34.503: as palavras se ligam com E |
| com acento ("vôo") | 12.898 |
| assunto 4829 | 21.867 |
| o que o termo pega | das 20 primeiras, 5 fora do ramo aéreo |

# A ficha da coleta

Antes de baixar qualquer coisa, anotar:

1. tribunal e grau (TJSP de 1º ou de 2º grau, STJ, STF)
2. termos exatos, com aspas e variações, ou assunto e classe
3. período, e por que ele
4. o que conta como decisão (sentença, acórdão, liminar)
5. data e hora da busca, e quantas decisões ela devolveu

Quem repetir a busca tem que chegar ao mesmo cadastro.

# Como sortear

# Como na consulta 3: as primeiras não são amostra

Na consulta 3, o escritório ia ler os 600 primeiros de 213.580 acórdãos. A ordem é do buscador, e não é amostra.

No nosso caso é igual: o site ordena da sentença mais recente, e na coleta-piloto as 20 primeiras eram todas de um dia só.

**Na prática**

Pegar a lista inteira do que a busca alcança e **sortear** dela as decisões a ler.

# Duas formas de escolher

**Por conveniência**

os casos em que você atuou, os de um conhecido, os que o colega já tinha separado

não dá para saber o quanto se parecem com o resto (Lohr, cap. 15)

VS

**Por sorteio**

toda decisão da lista tem a mesma chance de entrar

a diferença entre amostra e lista passa a ser só acaso, e o acaso se mede

# Quando comparar grupos

Se a pergunta compara atraso com cancelamento, e há poucos cancelamentos na lista, um sorteio simples pode trazer só um punhado deles.

Saída: separar a lista nos grupos que queremos comparar e sortear dentro de cada um.

**Para pensar**

Sorteio não corrige viés de seleção. Sortear das sentenças continua deixando de fora os processos parados.

# Desenhem a coleta para a companhia

Em grupo, para uma das perguntas A, B ou C:

1. o universo e o cadastro
2. os termos (ou o assunto) e o período
3. o que fica de fora, e se isso muda a resposta
4. como sortear, e se é preciso separar grupos

# Uma proposta para a pergunta A

**RESPOSTA**

| Item | Proposta |
|---|---|
| Fonte | sentenças do TJSP de 1º grau |
| Busca | assunto 4829, que não depende da grafia |
| Período | o ano antes de 26/11/2025 |
| Fora | acordos e processos sem sentença |
| Sorteio | separado para atraso e cancelamento |

# Viés de seleção

# Viés de seleção

A forma de escolher os casos faz os escolhidos serem diferentes, de modo sistemático, do conjunto sobre o qual se quer concluir.

Mais casos escolhidos do mesmo jeito não corrigem: 10.749 decisões achadas por "remédio" continuam achadas por "remédio".

Na consulta 1, a seleção veio do termo, do réu, do ano, da instância e da tese. E no nosso caso?

# Onde o viés mora

| Distância | O que resolve |
|---|---|
| entre a amostra e o cadastro | o sorteio: o que sobra é acaso, e o acaso se mede |
| entre o cadastro e o universo | o sorteio não resolve: é aqui que mora o viés de seleção |

Mudar a busca, juntar outra fonte, ou limitar a conclusão ao que o cadastro alcança (Lohr, seção 1.3).

# Antes e depois da suspensão

Um colega compara a taxa de vitória dos passageiros em sentenças de antes de 26/11/2025 e de depois.

Depois, a taxa sobe. A diferença mede o efeito do Tema 1.417?

# Não: depois, as sentenças são outras

**RESPOSTA**

Desde a suspensão, os processos que discutem as excludentes do art. 256, § 3º, do CBA estão parados. Os que continuam recebendo sentença são, em boa parte, os que a suspensão não alcança, como o fortuito interno.

A comparação põe lado a lado **populações diferentes**. Uma taxa maior depois pode vir só de quais casos chegam à sentença, e não de mudança no que os juízes decidem.

# O mesmo defeito, duas perguntas

| Pergunta | O que a busca em sentenças deixa de fora |
|---|---|
| C. Quanto a suspensão alcança | justamente os processos parados, que não têm sentença |
| A. Antes e depois | os casos com excludente, que pararam depois de 26/11/2025 |

Ler mais sentenças não conserta nenhum dos dois: o problema é **quais** chegam à fonte, e não quantas.

# Dados pessoais na coleta

# Dado pessoal e dado pessoal sensível

| LGPD, art. 5º | O que é |
|---|---|
| Dado pessoal (I) | informação relacionada a pessoa natural identificada ou identificável |
| Dado pessoal sensível (II) | dado pessoal sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização religiosa, filosófica ou política, saúde, vida sexual, dado genético ou biométrico |

# Na nossa base

Na base de sentenças de atraso de voo, o que é dado pessoal, e o que é dado pessoal sensível?

# O que guardar

**RESPOSTA**

| Na sentença | É | Na base |
|---|---|---|
| nome do passageiro | pessoal | não guardar |
| número do processo | pessoal | só se precisar |
| "estava grávida" | sensível | no máximo "saúde: sim" |
| nome da companhia | não é pessoal | guardar |

# Guardar só o que a pergunta precisa

A LGPD pede que o tratamento se limite ao mínimo necessário para a finalidade (art. 6º, III).

Na prática da coleta: a pergunta decide as colunas, e o que não responde a pergunta nenhuma não entra na base.

# O que sai desta aula

| Hoje | Vira, na aula 25 |
|---|---|
| as quatro perguntas | as colunas do codebook |
| o dado de cada pergunta | o tipo de cada coluna, e se sai por regex ou por modelo |
| a ficha da coleta e o sorteio | a base que vocês vão analisar nas aulas 26 e 27 |